

# Statistik Formelsammlung

Katharina Ring

3. April 2019

# Inhaltsverzeichnis

<b>1 Deskriptive Statistik</b>	<b>3</b>	<b>3 Hypothesentests</b>	<b>8</b>
1.1 Kenngrößen (Parameter): Stichprobe . . . . .	3	3.1 Tests für Einstichprobenprobleme . . . . .	8
1.1.1 Lagemaße . . . . .	3	3.1.1 Normalverteilung . . . . .	8
1.1.2 Streuungsmaße . . . . .	3		
1.1.3 Konzentrationsmaße . . . . .	3	<b>4 Regression</b>	<b>8</b>
1.1.4 Gestaltmaße . . . . .	4	4.1 Annahmen . . . . .	8
1.1.5 Zusammenhangsmaße . . . . .	4	4.2 Verfahren . . . . .	8
1.2 Tabellen . . . . .	5	4.2.1 Kleinste Quadrate (OLS) . . . . .	8
1.3 Diagramme . . . . .	5	4.2.2 Maximum Likelihood . . . . .	9
1.3.1 Histogramm . . . . .	5	4.3 Modell . . . . .	9
1.3.2 QQ-Plot . . . . .	5	4.3.1 lineare Einfachregression . . . . .	9
1.3.3 Plot der Realisationen . . . . .	5	4.3.2 Multivariate lineare Regression . . . . .	9
1.3.4 Scatterplot . . . . .	5	4.4 ANOVA (Streuungszerlegung) . . . . .	9
		4.5 Gütemaße . . . . .	9
<b>2 Wahrscheinlichkeit</b>	<b>5</b>	4.5.1 Bestimmtheitsmaß . . . . .	9
2.1 Kombinatorik . . . . .	5	<b>5 Klassifikation</b>	<b>9</b>
2.2 Wahrscheinlichkeitsrechnung . . . . .	5	5.1 Diskriminanzanalyse (Bayes) . . . . .	9
2.3 Zufallsvariablen . . . . .	6		
2.4 Verteilungen . . . . .	6	<b>6 Clusteranalyse</b>	<b>9</b>
2.4.1 Diskrete Verteilungen . . . . .	6		
2.4.2 Stetige Verteilungen . . . . .	7	<b>7 Bayessche Statistik</b>	<b>9</b>
2.4.3 Exponentialfamilie . . . . .	8	7.0.1 Grundlagen . . . . .	10
2.5 Grenzwertsätze . . . . .	8	7.0.2 Markov Chain / Monte Carlo . . . . .	10

# 1 Deskriptive Statistik

## 1.1 Kenngrößen (Parameter): Stichprobe

### 1.1.1 Lagemaße

**Modus** Häufigster Wert von  $x_i$ . Auch zwei oder mehr Modi sind möglich (bimodal).

**Median**

$$\tilde{x}_{0.5} = \begin{cases} x_{((n+1)/2)} & \text{falls } n \text{ ungerade} \\ \frac{1}{2}(x_{(n/2)} + x_{(n/2+1)}) & \text{falls } n \text{ gerade} \end{cases}$$

**Quantile**

$$\tilde{x}_\alpha = \begin{cases} x_{(k)} & \text{falls } n\alpha \notin \mathbb{N} \\ \frac{1}{2}(x_{(n\alpha)} + x_{(n\alpha+1)}) & \text{falls } n\alpha \text{ ganzzahlig} \end{cases}$$

mit

$$k = \min \{x \in \mathbb{N}, \quad x > n\alpha\}$$

**Minimum/Maximum**

$$x_{\min} = \min_{i \in \{1, \dots, N\}} (x_i) \quad x_{\max} = \max_{i \in \{1, \dots, N\}} (x_i)$$

### 1.1.2 Streuungsmaße

**Spannweite**

$$R = x_{(n)} - x_{(1)}$$

**Quartilsabstand**

$$d_Q = \tilde{x}_{0.75} - \tilde{x}_{0.25}$$

**(Empirische) Varianz**

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2$$

Schätzer für das zweite zentrierte Moment, inkl.

Varianzverschiebungssatz

*Rechenregeln:*

$$\star \operatorname{Var}(aX + b) = a^2 \cdot \operatorname{Var}(X)$$

### 1.1.3 Konzentrationsmaße

**Gini-Koeffizient**

$$G = \frac{2 \sum_{i=1}^n i x_{(i)} - (n+1) \sum_{i=1}^n x_{(i)}}{n \sum_{i=1}^n x_{(i)}} = 1 - \frac{1}{n} \sum_{i=1}^n (v_{i-1} + v_i)$$

mit

**Arithmetisches Mittel**

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Schätzer für den Erwartungswert  $\mu = E[X]$   
(erstes Verteilungsmoment)

*Rechenregeln:*

$$\star E(a + b \cdot X) = a + b \cdot E(X)$$

$$\star E(X \pm Y) = E(X) \pm E(Y)$$

**Geometrisches Mittel**

$$\bar{x}_G = \sqrt[n]{\sum_{i=1}^n x_i}$$

Für Wachstumsfaktoren:  $\bar{x}_G = \sqrt[n]{\frac{B_n}{B_0}}$

**Harmonisches Mittel**

$$\bar{x}_H = \frac{\sum_{i=1}^n w_i}{\sum_{i=1}^n \frac{w_i}{x_i}}$$

$$\star \operatorname{Var}(X \pm Y) = \operatorname{Var}(X) + \operatorname{Var}(Y) + 2\operatorname{Cov}(X, Y)$$

**(Empirische) Standardabweichung**

$$s = \sqrt{s^2}$$

**Variationskoeffizient**

$$\nu = \frac{s}{\bar{x}}$$

**Mittlere absolute Abweichung**

$$e = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

Schätzer für das erste absolute zentrierte Moment

$$u_i = \frac{i}{n}, \quad v_i = \frac{\sum_{j=1}^i x_{(j)}}{\sum_{j=1}^n x_{(j)}} \quad (u_0 = 0, \quad v_0 = 0)$$

Dies sind auch die Werte für die Lorenzkurve.

$$\text{Wertebereich: } 0 \leq G \leq \frac{n-1}{n}$$

**Lorenz-Münzner-Koeffizient** ( $G$  normiert)

$$G^+ = \frac{n}{n-1}G$$

Wertebereich:  $0 \leq G^+ \leq 1$

### 1.1.4 Gestaltmaße

**(Empirische) Schiefe**

$$\nu = \frac{n}{(n-1)(n-2)} \sum_{i=1}^n \left( \frac{x_i - \bar{x}}{s} \right)^3$$

Schätzer für das dritte zentrierte Moment, normiert durch  $(\sigma^2)^{\frac{3}{2}}$

**(Empirische) Wölbung/Kurtosis**

$$k = \left[ n(n+1) \cdot \sum_{i=1}^n \left( \frac{x_i - \bar{x}}{s} \right)^4 - 3(n-1) \right] \cdot \frac{n-1}{(n-2)(n-3)} + 3$$

Schätzer für das vierte zentrierte Moment, normiert durch  $(\sigma^2)^2$

**Exzess**

$$\gamma = k - 3$$

### 1.1.5 Zusammenhangsmaße

#### *Für zwei nominale Variablen*

**$\chi^2$ -Statistik**

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^l \frac{(n_{ij} - \frac{n_{i+}n_{+j}}{n})^2}{\frac{n_{i+}n_{+j}}{n}} = n \left( \sum_{i=1}^k \sum_{j=1}^l \frac{n_{ij}^2}{n_{i+}n_{+j}} - 1 \right)$$

Wertebereich:  $0 \leq \chi^2 \leq n(\min(k, l) - 1)$

**Phi-Koeffizient**

$$\Phi = \sqrt{\frac{\chi^2}{n}}$$

Wertebereich:  $0 \leq \Phi \leq \sqrt{\min(k, l) - 1}$

**Cramér's  $V$**

$$V = \sqrt{\frac{\chi^2}{\min(k, l) - 1}}$$

Wertebereich:  $0 \leq V \leq 1$

**Kontingenzkoeffizient  $C$**

$$C = \sqrt{\frac{\chi^2}{\chi^2 + n}}$$

Wertebereich:  $0 \leq C \leq \sqrt{\frac{\min(k, l) - 1}{\min(k, l)}}$

**Korrigierter Kontingenzkoeffizient  $C_{\text{corr}}$**

$$C_{\text{corr}} = \sqrt{\frac{\min(k, l)}{\min(k, l) - 1}} \cdot \sqrt{\frac{\chi^2}{\chi^2 + n}}$$

Wertebereich:  $0 \leq C_{\text{corr}} \leq 1$

**Odds-Ratio**

$$OR = \frac{ad}{bc} = \frac{n_{ii}n_{jj}}{n_{ij}n_{ji}}$$

Wertebereich:  $0 \leq OR < \infty$

#### *Für zwei ordinale Variablen*

**Gamma nach Goodman und Kruskal**

$$\gamma = \frac{K - D}{K + D}$$

$K = \sum_{i < m} \sum_{j < n} n_{ij}n_{mn}$  Anzahl konkordanter Paare

$D = \sum_{i < m} \sum_{j > n} n_{ij}n_{mn}$  Anzahl diskordanter Paare

Wertebereich:  $-1 \leq \gamma \leq 1$

**Kendalls  $\tau_b$**

$$\tau_b = \frac{K - D}{\sqrt{(K + D + T_X)(K + D + T_Y)}}$$

mit

$T_X = \sum_{i=m} \sum_{j < n} n_{ij}n_{mn}$  Anzahl Bindungen bzgl.  $X$

$T_Y = \sum_{i < m} \sum_{j=n} n_{ij}n_{mn}$  Anzahl Bindungen bzgl.  $Y$

Wertebereich:  $-1 \leq \tau_b \leq 1$

**Kendalls/Stuarts  $\tau_c$**

$$\tau_c = \frac{2 \min(k, l)(K - D)}{n^2(\min(k, l) - 1)}$$

Wertebereich:  $-1 \leq \tau_c \leq 1$

**Spearman's Rangkorrelationskoeffizient**

$$\rho = \frac{n(n^2 - 1) - \frac{1}{2} \sum_{j=1}^J b_j(b_j^2 - 1) - \frac{1}{2} \sum_{k=1}^K c_k(c_k^2 - 1) - 6 \sum_{i=1}^n d_i^2}{\sqrt{n(n^2 - 1) - \sum_{j=1}^J b_j(b_j^2 - 1)} \sqrt{n(n^2 - 1) - \sum_{k=1}^K c_k(c_k^2 - 1)}}$$

oder

$$\rho = \frac{s_{rg_x} r_{g_y}}{\sqrt{s_{rg_x} r_{g_x} s_{rg_y} r_{g_y}}}$$

Entspricht ohne Bindungen:

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

mit

$d_i = R(x_i) - R(y_i)$  Rangdifferenz

Wertebereich:  $-1 \leq \rho \leq 1$

## Für zwei metrische Variablen

Korrelationskoeffizient nach Bravais-Pearson

$$r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}} = \frac{s_{xy}}{\sqrt{s_{xx}s_{yy}}}$$

mit


$$\begin{aligned} S_{xy} &= \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) & \text{bzw. } s_{xy} &= \frac{S_{xy}}{n} \\ S_{xx} &= \sum_{i=1}^n (x_i - \bar{x})^2 & \text{bzw. } s_{xx} &= \frac{S_{xx}}{n} \\ S_{yy} &= \sum_{i=1}^n (y_i - \bar{y})^2 & \text{bzw. } s_{yy} &= \frac{S_{yy}}{n} \end{aligned}$$

Wertebereich:  $-1 \leq r \leq 1$

## 1.2 Tabellen

## 1.3 Diagramme

### 1.3.1 Histogramm



Stichprobe:  $X = \{x_1, x_2, \dots, x_n\}$   
 $k$ -te Klasse:  $B_k = [t_k, t_{k+1})$ ,  $k = \{0, 1, \dots, m-1\}$   
 Anzahl Beobachtungen in der  $k$ -ten Klasse:  $v_k$   
 Klassenbreite:  $h = t_{k+1} - t_k, \forall k$

Scotts Regel

$$h^* \approx 3.5\sigma n^{-\frac{1}{3}}$$

Für annähernd normalverteilte Daten (min MSE)

### 1.3.2 QQ-Plot

### 1.3.3 Plot der Realisationen

### 1.3.4 Scatterplot

## 2 Wahrscheinlichkeit

### 2.1 Kombinatorik

	ohne Wiederholung	mit Wiederholung
Permutationen	$n!$	$\frac{n!}{n_1! \dots n_s!}$
Kombinationen: ohne Reihenfolge	$\binom{n}{m}$	$\binom{n+m-1}{m}$
mit Reihenfolge	$\binom{n}{m} m!$	$n^m$

Dabei gilt:

$$n! = n \cdot (n-1) \cdot \dots \cdot 1$$

$$\binom{n}{m} = \frac{n!}{m!(n-m)!}$$

## 2.2 Wahrscheinlichkeitsrechnung

Laplace-Wahrscheinlichkeit

$$P(A) = \frac{|A|}{|\Omega|}$$

Axiome von Kolmogorov

mathematische Definition von Wahrscheinlichkeit

- (1)  $0 \leq P(A) \leq 1 \quad \forall A \in \mathcal{A}$
- (2)  $P(\Omega) = 1$
- (3)  $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$   
 $\forall A_i \in \mathcal{A}, i = 1, \dots, \infty$  mit  $A_i \cap A_j = \emptyset$  für  $i \neq j$

Folgerungen:

- $P(\bar{A}) = 1 - P(A)$

- $P(\emptyset) = 0$
- $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- $A \subseteq B \Rightarrow P(A) \leq P(B)$
- $P(B) = \sum_{i=1}^n P(B \cap A_i)$ , für  $A_1, \dots, A_n$  vollständige Zerlegung von  $\Omega$  in paarweise disjunkte Ereignisse

Mises' Wahrscheinlichkeitsbegriff

frequentistische Definition von Wahrscheinlichkeit

$$P(A) = \lim_{n \rightarrow \infty} \frac{n_A(n)}{n}$$

mit  $n$  Anzahl der Wiederholungen eines Zufallsexperiments und  $n_A(n)$  Anzahl an Ereignissen  $A$

### Bedingte Wahrscheinlichkeit

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad \text{für } P(B) > 0$$

### Multiplikationssatz

$$P(A \cap B) = P(B|A)P(A) = P(A|B)P(B)$$

### Satz von der totalen Wahrscheinlichkeit

$$P(B) = \sum_{i=1}^n P(B|A_i)P(A_i)$$

## 2.3 Zufallsvariablen

### Definition

$$Y : \Omega \rightarrow \mathbb{R}$$

Die Untermenge möglicher Werte von  $\mathbb{R}$  heißt Träger  
Notation: Realisationen von  $Y$  werden als Kleinbuchstaben dargestellt.  $Y = y$  bedeutet, dass  $Y$  die Realisation  $y$  angenommen hat.

### Stetige und diskrete Zufallsvariablen

Ist der Träger überabzählbar unendlich, so heißt die Zufallsvariable *stetig*, sonst heißt sie *diskret*.

- **Dichte  $f(\cdot)$ :**

Für stetige Variablen:  $P(Y \in [a, b]) = \int_a^b f_Y(y) dy$

Für diskrete Variablen lässt sich die Dichte (und andere Funktionen) wie die gleichen Funktionen für den stetigen Fall aufschreiben, wenn man  $\int_{-\infty}^y f_Y(\tilde{y}) d\tilde{y} := \sum_{k: k \leq y} P(Y = k)$  definiert. Diese Notation wird hier verwendet.

- **Verteilungsfunktion  $F(\cdot)$ :**  $F_Y(y) = P(Y \leq y)$

### Satz von Bayes

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} \quad \text{für } P(A), P(B) > 0$$

### Stochastische Unabhängigkeit

$$A, B \text{ unabhängig} \Leftrightarrow P(A \cap B) = P(A) \cdot P(B)$$

$$X, Y \text{ unabhängig} \Leftrightarrow f_{XY}(x, y) = f_X(x) \cdot f_Y(y) \quad \forall x, y$$

### Zusammenhang:

$$F_Y(y) = \int_{-\infty}^y f_Y(\tilde{y}) d\tilde{y}$$

Ist der Träger endlich oder abzählbar unendlich, so heißt die Zufallsvariable *diskret*.

### Momente

- **Erwartungswert (1. Moment):**  $\mu = E(Y) = \int y f_Y(y) dy$

- **Varianz (2. zentriertes Moment):**

$$\sigma^2 = \text{Var}(Y) = E(\{Y - E(Y)\}^2) = \int (y - E(Y))^2 f(y) dy$$

$$\text{Varianzverschiebungssatz: } E(\{Y - \mu\}^2) = E(Y^2) - \mu^2$$

Beweis:

$$E(\{Y - \mu\}^2) = E(Y^2 - 2Y\mu + \mu^2) = E(Y^2) - 2\mu^2 + \mu^2 = E(Y^2) - \mu^2$$

- **k. Moment:**  $E(Y^k) = \int y^k f_Y(y) dy$ ,  
**k. zentrales Moment:**  $E(\{Y - E(Y)\}^k)$

## 2.4 Verteilungen

### 2.4.1 Diskrete Verteilungen

#### Diskrete Gleichverteilung

$$Y \sim U(\{y_1, \dots, y_k\}), \quad y \in \{y_1, \dots, y_k\}$$

$$P(Y = y_i) = \frac{1}{k}, \quad i = 1, \dots, k$$

$$E(Y) = \frac{k+1}{2}, \quad \text{Var}(Y) = \frac{k^2-1}{12}$$

#### Binomialverteilung

Erfolge in unabhängigen Versuchen

$$Y \sim \text{Bin}(n, \pi) \text{ mit } n \in \mathbb{N}, \pi \in [0, 1], y \in \{0, \dots, n\}$$

$$P(Y = y|\lambda) = \binom{n}{y} \pi^y (1 - \pi)^{n-y}$$

$$E(Y|\pi, n) = n\pi, \quad \text{Var}(Y|\pi, n) = n\pi(1 - \pi)$$

#### Poissonverteilung

Zählmodelle für seltene Ereignisse

Immer nur ein Ereignis pro Zeitpunkt, Eintreten der Ereignisse ist unabhängig von bisheriger Geschichte, mittlere Anzahl der

Ereignisse pro Zeit ist konstant und proportional zur Länge des betrachteten Zeitintervalls.

$$Y \sim \text{Po}(\lambda) \text{ mit } \lambda \in [0, +\infty], y \in \mathbb{N}_0$$

$$P(Y = y|\lambda) = \frac{\lambda^y \exp^{-\lambda}}{y!}$$

$$E(Y|\lambda) = \lambda, \quad \text{Var}(Y|\lambda) = \lambda$$

Häufig wird die Varianz durch das Poisson-Modell unterschätzt, es liegt Überdispersion vor.

*Approximation* der Binomialverteilung für kleine  $p$

### Geometrische Verteilung

$$\begin{aligned} Y &\sim \text{Geom}(\pi) \text{ mit } \pi \in [0, 1], y \in \mathbb{N}_0 \\ P(Y = y|\pi) &= \pi(1 - \pi)^{y-1} \\ E(Y|\pi) &= \frac{1}{\pi}, \text{ Var}(Y|\pi) = \frac{1 - \pi}{\pi^2} \end{aligned}$$

## 2.4.2 Stetige Verteilungen

### Stetige Gleichverteilung

$$\begin{aligned} Y &\sim U(a, b) \text{ mit } \alpha, \beta \in \mathbb{R}, a \leq b, y \in [a, b] \\ p(y|a, b) &= \frac{1}{b - a} \\ E(Y|a, b) &= \frac{a + b}{2}, \text{ Var}(Y|a, b) = \frac{(b - a)^2}{12} \end{aligned}$$

### Univariate Normalverteilung

 symmetrisch mit  $\mu$  und  $\sigma^2$ 

$$\begin{aligned} Y &\sim N(\mu, \sigma^2) \text{ mit } \mu \in \mathbb{R}, \sigma^2 > 0, y \in \mathbb{R} \\ p(y|\mu, \sigma^2) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y - \mu)^2}{2\sigma^2}\right) \\ E(Y|\mu, \sigma^2) &= \mu, \text{ Var}(Y|\mu, \sigma^2) = \sigma^2 \end{aligned}$$

### Multivariate Normalverteilung

 symmetrisch mit  $\mu$  und  $\Sigma$ 

$$\begin{aligned} Y &\sim N(\mu, \Sigma) \text{ mit } \mu \in \mathbb{R}^d, \Sigma \in \mathbb{R}^{d \times d} \text{ s.p.d.}, y \in \mathbb{R}^d \\ p(y|\mu, \Sigma) &= (2\pi)^{-\frac{d}{2}} \det(\Sigma)^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(y - \mu)^T \Sigma^{-1}(y - \mu)\right) \\ E(Y|\mu, \Sigma) &= \mu, \text{ Var}(Y|\mu, \Sigma) = \Sigma \end{aligned}$$

### Log-Normalverteilung

$$\begin{aligned} Y &\sim \text{LogN}(\mu, \sigma^2) \text{ mit } \mu \in \mathbb{R}, \sigma^2 > 0, y > 0 \\ p(y|\mu, \sigma^2) &= \frac{1}{\sqrt{2\pi\sigma^2}y} \exp\left(-\frac{(\log y - \mu)^2}{2\sigma^2}\right) \\ E(Y|\mu, \sigma^2) &= \exp\left(\mu + \frac{\sigma^2}{2}\right), \\ \text{Var}(Y|\mu, \sigma^2) &= \exp(2\mu + \sigma^2)(\exp(\sigma^2) - 1) \end{aligned}$$

Zusammenhang:  $\log(Y) \sim N(\mu, \sigma^2) \Rightarrow Y \sim \text{LogN}(\mu, \sigma^2)$

### Nichtzentrale Studentverteilung

 statistische Tests für  $\mu$  mit unbekannter (geschätzter) Varianz und  $\nu$  Freiheitsgraden

$$\begin{aligned} Y &\sim t_\nu(\mu, \sigma) \text{ mit } \mu \in \mathbb{R}, \sigma^2, \nu > 0, y \in \mathbb{R} \\ p(y|\mu, \sigma^2, \nu) &= \frac{\Gamma(\frac{\nu+1}{2})}{\Gamma(\frac{\nu}{2})\Gamma(\sqrt{\nu\pi\sigma})} \left(1 + \frac{(y - \mu)^2}{\nu\sigma^2}\right)^{-\frac{\nu+1}{2}} \\ E(Y|\mu, \sigma^2, \nu) &= \mu \text{ für } \nu > 1, \\ \text{Var}(Y|\mu, \sigma^2, \nu) &= \sigma^2 \frac{\nu}{\nu - 2} \text{ für } \nu > 2 \end{aligned}$$

Zusammenhang:  $Y|\theta \sim N(\mu, \frac{\sigma^2}{\theta}), \theta \sim \text{Ga}(\frac{\nu}{2}, \frac{\nu}{2}) \Rightarrow Y \sim t_\nu(\mu, \sigma)$

### Negative Binomialverteilung

$$\begin{aligned} Y &\sim \text{NegBin}(\alpha, \beta) \text{ mit } \alpha, \beta \geq 0, y \in \mathbb{N}_0 \\ P(Y = y|\alpha, \beta) &= \binom{\alpha + y - 1}{\alpha - 1} \left(\frac{\beta}{\beta - 1}\right)^\alpha \left(\frac{1}{\beta + 1}\right)^y \\ E(Y|\alpha, \beta) &= \frac{\alpha}{\beta}, \text{ Var}(Y|\alpha, \beta) = \frac{\alpha}{\beta^2}(\beta + 1) \end{aligned}$$

### Betaverteilung

$$\begin{aligned} Y &\sim \text{Be}(a, b) \text{ mit } a, b > 0, y \in [0, 1] \\ p(y|a, b) &= \frac{\Gamma(a + b)}{\Gamma(a)\Gamma(b)} y^{a-1}(1 - y)^{b-1} \\ E(Y|a, b) &= \frac{a}{a + b}, \\ \text{Var}(Y|a, b) &= \frac{ab}{(a + b)^2(a + b + 1)}, \\ \text{mod}(Y|a, b) &= \frac{a - 1}{a + b - 2} \text{ für } a, b > 1 \end{aligned}$$

### Gammaverteilung

$$\begin{aligned} Y &\sim \text{Ga}(a, b) \text{ mit } a, b > 0, y > 0 \\ p(y|a, b) &= \frac{b^a}{\Gamma(a)} y^{a-1} \exp(-by) \\ E(Y|a, b) &= \frac{a}{b}, \\ \text{Var}(Y|a, b) &= \frac{a}{b^2}, \\ \text{mod}(Y|a, b) &= \frac{a - 1}{b} \text{ für } a \geq 1 \end{aligned}$$

### Invers-Gammaverteilung

$$\begin{aligned} Y &\sim \text{IG}(a, b) \text{ mit } a, b > 0, y > 0 \\ p(y|a, b) &= \frac{b^a}{\Gamma(a)} y^{-a-1} \exp\left(-\frac{b}{y}\right) \\ E(Y|a, b) &= \frac{b}{a - 1} \text{ für } a > 1, \\ \text{Var}(Y|a, b) &= \frac{b^2}{(a - 1)^2(a - 2)} \text{ für } a \geq 2, \\ \text{mod}(Y|a, b) &= \frac{b}{a + 1} \end{aligned}$$

Zusammenhang:  $Y^{-1} \sim \text{Ga}(a, b) \Leftrightarrow Y \sim \text{IG}(a, b)$

### Exponentialverteilung

 Zeit zwischen Poisson-Ereignissen

$$\begin{aligned} Y &\sim \text{Exp}(\lambda) \text{ mit } \lambda > 0, y \geq 0 \\ p(y|\lambda) &= \lambda \exp(-\lambda y) \\ E(Y|\lambda) &= \frac{1}{\lambda}, \text{ Var}(Y|\lambda) = \frac{1}{\lambda^2} \end{aligned}$$

### Chi-Quadrat-Verteilung

 quadrierte standardnormalverteilte Zufallsvariablen mit  $\nu$  Freiheitsgraden

$$\begin{aligned} Y &\sim \chi^2(\nu) \text{ mit } \nu > 0, y \in \mathbb{R} \\ p(y|\nu) &= \frac{y^{\frac{\nu}{2}-1} e^{-\frac{y}{2}}}{2^{\frac{\nu}{2}} \Gamma(\frac{\nu}{2})} \\ E(Y|\nu) &= \nu, \text{ Var}(Y|\nu) = 2\nu \end{aligned}$$

## 2.4.3 Exponentialfamilie

### Definition

Zur Exponentialfamilie gehören alle Verteilungen, deren Dichte wie folgt geschrieben werden kann:

$$f_Y(y, \theta) = \exp^{t^T(y)\theta - \kappa(\theta)} h(y)$$

mit  $h(y) \geq 0$ ,  $t(y)$  Vektor der kanonischen Statistiken,  $\theta$  Parametervektor und  $\kappa(\theta)$  Normalisationskonstante.

### Normalisierungskonstante

$$1 = \int \exp^{t^T(y)\theta} h(y) dy \exp^{-\kappa(\theta)}$$
$$\Leftrightarrow \kappa(\theta) = \log \int \exp^{t^T(y)\theta} h(y) dy$$

$\kappa(\theta)$  ist die kumulanterzeugende Funktion, somit  $\frac{\partial \kappa(\theta)}{\partial \theta} = E(t(Y))$  und  $\frac{\partial^2 \kappa(\theta)}{\partial \theta^2} = \text{Var}(t(Y))$

### Mitglieder

- Poissonverteilung
- Geometrische Verteilung
- Exponentialverteilung
- Normalverteilung  $t(y) = \left(-\frac{y^2}{2}, y\right)^T$ ,  $\theta = \left(\frac{1}{\sigma^2}, \frac{\mu}{\sigma^2}\right)^T$ ,  
 $h(y) = \frac{1}{\sqrt{2\pi}}$ ,  $\kappa(\theta) = \frac{1}{2} \left(-\log \frac{1}{\sigma^2} + \frac{\mu^2}{\sigma^2}\right)$
- Gammaverteilung
- Chi-Quadrat-Verteilung
- Betaverteilung

## 2.5 Grenzwertsätze

# 3 Hypothesentests

Gesetz der großen Zahlen

## 3.1 Tests für Einstichprobenprobleme

### 3.1.1 Normalverteilung

# 4 Regression

$\mu$  gesucht,  $\sigma^2$  bekannt (Einfacher Gauß-Test)

## 4.1 Annahmen

## 4.2 Verfahren

### 4.2.1 Kleinste Quadrate (OLS)

#### KQ-Schätzer (Einfachregression)

$$\hat{\beta}_1 = \frac{\text{Cov}(x, y)}{\text{Var}(x)} = \frac{S_{xy}}{S_{xx}} = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}} \cdot \sqrt{\frac{S_{yy}}{S_{xx}}} = r \sqrt{\frac{S_{yy}}{S_{xx}}}$$

Beweis:

$$\text{Cov}(x, y) = \text{Cov}(x, \hat{\beta}_0 + \hat{\beta}_1 \bar{x}) = \hat{\beta}_1 \text{Var}(x)$$
$$\Leftrightarrow \hat{\beta}_1 = \frac{\text{Cov}(x, y)}{\text{Var}(x)}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Beweis:

$$E[y] = E[\hat{\beta}_0 + \hat{\beta}_1 x + \hat{e}] \Leftrightarrow \hat{\beta}_0 = E[y] - \hat{\beta}_1 E[x]$$



### 4.2.2 Maximum Likelihood

## 4.3 Modell

### 4.3.1 lineare Einfachregression

#### Theoretisches Modell

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

#### Empirisches Modell

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i + e_i$$

#### Eigenschaften der Regressionsgeraden

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i = \bar{y} + \hat{\beta}_1 (x_i - \bar{x})$$

$$\hat{e}_i = y_i - \hat{y}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$$

$$= y_i - (\bar{y} + \hat{\beta}_1 (x_i - \bar{x}))$$

$$\sum_{i=1}^n \hat{e}_i = \sum_{i=1}^n y_i - \sum_{i=1}^n \bar{y} - \hat{\beta}_1 \sum_{i=1}^n (x_i - \bar{x})$$

$$= n\bar{y} - n\bar{y} - \hat{\beta}_1 (n\bar{x} - n\bar{x}) = 0$$

$$\bar{\hat{y}} = \frac{1}{n} \sum_{i=1}^n \hat{y}_i = \frac{1}{n} (n\bar{y} + \hat{\beta}_1 (n\bar{x} - n\bar{x})) = \bar{y}$$

### 4.3.2 Multivariate lineare Regression

## 4.4 ANOVA (Streuungszerlegung)

$$SS_{Total} = SS_{Explained} + SS_{Residual}$$

mit

$$SS_{Total} = \sum_{i=1}^n (y_i - \bar{y})^2$$

$$SS_{Explained} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

$$SS_{Residual} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n e_i^2 = S_{yy} - \hat{\beta}^2 S_{xx}$$

## 4.5 Gütemaße

### 4.5.1 Bestimmtheitsmaß

$$R^2 = \frac{SS_{Explained}}{SS_{Total}} = 1 - \frac{SS_{Residual}}{SS_{Total}} = r^2$$

Wertebereich:  $0 \leq R^2 \leq 1$

## 5 Klassifikation

### 5.1 Diskriminanzanalyse (Bayes)

## 6 Clusteranalyse

## 7 Bayessche Statistik

## 7.0.1 Grundlagen

### Bayes-Formel

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} \quad \text{für } P(A), P(B) > 0$$

oder allgemeiner:

$$\begin{aligned} f(\theta|X) &= \frac{f(X|\theta) \cdot f(\theta)}{\int f(X|\tilde{\theta})f(\tilde{\theta})d\tilde{\theta}} \\ &= C \cdot f(X|\theta) \cdot f(\theta) \quad \text{wähle C so, dass } \int f(\theta|X) = 1 \\ &\propto f(X|\theta) \cdot f(\theta) \end{aligned}$$

### Punktschätzer

### Kreditibilitätsintervall

### Sensitivitätsanalyse

### Prädiktive Posteriori

$$f(x_Z|\mathbf{x}) = \int f(x_Z, \lambda|\mathbf{x})d\lambda = \int f(x_Z|\lambda)p(\lambda|\mathbf{x})$$

### Uninformative Priori

$f(\theta) = \text{const.}$  für  $\theta > 0$ , damit:  $f(\theta|X) = C \cdot f(X|\theta)$   
(Da  $\int f(\theta) = 1$  so nicht möglich, ist das eigentlich keine Dichte)

### Konjugierte Priori

Wenn die Priori- und die Posteriori-Verteilung denselben Typ hat für eine gegebene Likelihoodfunktion, so nennt man sie konjugiert.

Binomial-Beta-Modell:

- Priori  $\sim Be(\alpha, \beta)$
- $X \sim Binom(n, p, k)$
- Posteriori  $\sim Be(\alpha + k, \beta + n - k)$

## 7.0.2 Markov Chain / Monte Carlo